

THÔNG TIN CHUNG CỦA NHÓM

- Link YouTube video của báo cáo (tối đa 5 phút): https://youtu.be/4Z7FJ-Ru6_U
- Link slides (dạng .pdf đặt trên Github của nhóm):
<https://github.com/nh4ttruong/CS2205.CH201/blob/main/Tr%C6%B0%E1%BB%9Dng%20Tr%E1%BA%A7n%20B%C3%B9i%20Nh%E1%BA%ADt%20-%20CS2205.SEP2025.DeCuong.FinalReport.Template.Slide.pdf>
- *Mỗi thành viên của nhóm điền thông tin vào một dòng theo mẫu bên dưới*
- *Sau đó điền vào Đề cương nghiên cứu (tối đa 5 trang), rồi chọn Turn in*
- *Lớp Cao học, mỗi nhóm một thành viên*

- Họ và Tên: Trần Bùi Nhật Trường
- MSSV: 250202024



- Lớp: CS2205.CH201
- Tự đánh giá (điểm tổng kết môn): 9/10
- Số buổi vắng: 0
- Số câu hỏi QT cá nhân: 5
- Số câu hỏi QT của cả nhóm: 0
- Link Github:
<https://github.com/nh4ttruong/CS2205.CH201>

ĐỀ CƯƠNG NGHIÊN CỨU

TÊN ĐỀ TÀI (IN HOA)

SUY LUẬN VÀ PHÁT HIỆN BẤT THƯỜNG BẰNG PHƯƠNG PHÁP
ZERO-SHOT VỚI CÁC MÔ HÌNH NGÔN NGỮ LỚN ĐA PHƯƠNG THỨC

TÊN ĐỀ TÀI TIẾNG ANH (IN HOA)

TOWARDS ZERO-SHOT ANOMALY DETECTION AND REASONING WITH
MULTIMODAL LARGE LANGUAGE MODELS

TÓM TẮT *(Tối đa 400 từ)*

Phát hiện bất thường (AD) là bài toán thị giác máy tính quan trọng trong kiểm soát chất lượng và chẩn đoán y tế. Các phương pháp học sâu truyền thống đòi hỏi lượng lớn dữ liệu gán nhãn, thúc đẩy sự phát triển của Zero-Shot AD (ZSAD). Tuy nhiên, ZSAD hiện tại còn thiếu khả năng giải thích, trong khi Mô hình Ngôn ngữ lớn Đa phương thức (MLLMs) mạnh về suy luận lại hạn chế trong việc nhận diện chi tiết bất thường tinh vi.

Nghiên cứu này đề xuất khung ZSAD, Anomaly-OneVision (Anomaly-OV), tận dụng khả năng quan sát chi tiết và suy luận minh bạch của MLLMs. Kiến trúc này sử dụng cơ chế Look-Twice Feature Matching (LTFM) lấy cảm hứng từ thị giác con người, thực hiện quan sát hai giai đoạn: tổng thể và tập trung tự động vào các token thị giác nghi ngờ. Điều này giúp mô hình nhận diện hiệu quả bất thường cục bộ mà không cần bộ mã hóa văn bản.

Nghiên cứu cũng xây dựng bộ dữ liệu tinh chỉnh chỉ thị Anomaly-Instruct-125k và chuẩn đánh giá VisA-D&R. Thực nghiệm cho thấy Anomaly-OV đạt hiệu suất vượt trội trên MVTec AD (94.0%) và VisA (91.1%), thể hiện khả năng suy luận ngôn ngữ mạch lạc và tổng quát hóa tốt, dễ dàng mở rộng sang dữ liệu y tế và 3D, khẳng định tiềm năng ứng dụng lớn.

GIỚI THIỆU *(Tối đa 1 trang A4)*

Phát hiện bất thường (Anomaly Detection - AD) đóng vai trò nền tảng trong kiểm soát chất lượng và chẩn đoán y tế, với mục tiêu nhận diện các lỗi hiếm gặp. Tuy nhiên, các phương pháp học sâu giám sát truyền thống bộc lộ nhiều hạn chế, chủ yếu do yêu cầu về lượng lớn dữ liệu bình thường và chi phí gán nhãn cao. Bên cạnh đó, chúng còn thiếu khả năng giải thích rõ ràng cơ chế lỗi.

Các phương pháp Phát hiện Bất thường Zero-Shot (Zero-Shot AD - ZSAD) được phát triển nhằm khắc phục những nhược điểm trên, song phần lớn vẫn chưa thể cung cấp lời giải thích minh bạch. Mặc dù các Mô hình Ngôn ngữ Lớn Đa phương thức (Multimodal Large Language Models - MLLMs) như GPT-4o sở hữu khả năng suy luận vượt trội, chúng vẫn còn hạn chế trong việc nhận diện các chi tiết bất thường tinh vi.

Trước thực trạng này, nghiên cứu đề xuất đề tài **“Suy luận và Phát hiện Bất thường bằng Phương pháp Zero-Shot với các Mô hình Ngôn ngữ Lớn Đa phương thức”** nhằm tích hợp hiệu quả ZSAD và MLLMs.

Nghiên cứu giới thiệu kiến trúc Anomaly-OneVision (Anomaly-OV) được trang bị cơ chế Look-Twice Feature Matching (LTFM) và Visual Token Selector (VT Selector). Kiến trúc này mô phỏng quy trình thị giác của con người thông qua hai giai đoạn: tổng quan toàn bộ và tự động tập trung vào các token bất thường để phân tích sâu. Điều này cho phép mô hình phát hiện hiệu quả các bất thường cục bộ mà không cần phụ thuộc vào bộ mã hóa văn bản truyền thống, đồng thời tự động suy luận được nguyên nhân gốc rễ của lỗi. Nghiên cứu cũng đóng góp các tài nguyên dữ liệu và chuẩn đánh giá mới.

MỤC TIÊU *(Viết trong vòng 3 mục tiêu)*

Đề tài hướng tới việc giải quyết các thách thức nêu trên thông qua ba mục tiêu sau:

1. Xây dựng bộ dữ liệu huấn luyện chuyên biệt Anomaly-Instruct-125k với số lượng dự kiến 125.000 mẫu, bao gồm các cặp hình ảnh - văn bản hội thoại chi tiết về lỗi sản phẩm.
2. Đề xuất, phát triển và xây dựng mô hình Anomaly-OV hoạt động như một mô hình MLLMs chuyên biệt tích hợp cơ chế mô phỏng mắt người LTFM, giúp hệ thống có khả năng tự động tập trung vào các chi tiết nhỏ mà các mô hình tổng quát thường bỏ qua.
3. Xây dựng bộ tiêu chí và tập dữ liệu kiểm thử chuẩn VisA-D&R để định lượng chính xác khả năng suy luận và phát hiện của mô hình so với các phương pháp tiên tiến.

NỘI DUNG VÀ PHƯƠNG PHÁP

Để giải quyết các mục tiêu đã đề ra, chúng tôi đề xuất quy trình nghiên cứu gồm 3 nội dung chính, với các phương pháp thực hiện cụ thể như sau:

1. Xây dựng bộ dữ liệu huấn luyện Anomaly-Instruct-125k

Nội dung này là bước nền tảng nhằm giải quyết vấn đề thiếu hụt dữ liệu hội thoại (instruction data) cho các tác vụ suy luận bất thường. Phương pháp thực hiện dự kiến bao gồm:

- Thiết lập quy trình thu thập tự động (WebAD pipeline) với một pipeline tự động hóa kết hợp giữa các mô hình ngôn ngữ lớn và công cụ tìm kiếm hình ảnh:
 - Sử dụng GPT-4o để sinh danh sách từ khóa mô tả trạng thái “bình thường” và “bất thường” cho 400 loại đối tượng phổ biến trong đời sống và công nghiệp.
 - Xây dựng script để tải xuống hình ảnh từ internet (WebAD) dựa trên các từ khóa này.

- Áp dụng mô hình CLIP (Radford et al., ICML 2021) để trích xuất đặc trưng và loại bỏ các ảnh trùng lặp dựa trên độ tương đồng cosine. Đồng thời, sử dụng GPT-4o để xác minh lại nhãn (bình thường, lỗi) nhằm đảm bảo độ sạch của dữ liệu huấn luyện.
- Tạo dữ liệu chỉ thị bằng cách sử dụng kỹ thuật In-context Learning”
 - Cung cấp cho GPT-4o các hình ảnh đi kèm bounding box đánh dấu vùng lỗi, được tạo từ mặt nạ phân đoạn có sẵn trong các bộ dữ liệu như MVTec AD và VisA
 - GPT-4o sẽ đóng vai trò “giáo viên” để sinh ra các đoạn hội thoại hỏi - đáp đa vòng (multi-round QA), bao gồm mô tả lỗi, nguyên nhân tiềm năng và giải pháp khắc phục.

2. Phát triển kiến trúc mô hình Anomaly-OneVision (Anomaly-OV)

Chúng tôi sẽ thiết kế và cài đặt một mô hình đa phương thức chuyên biệt, sử dụng LLaVA-OneVision làm nền tảng, xương sống cho mô hình Anomaly-OV.


Đầu tiên, thiết kế cơ chế Look-Twice Feature Matching (LTFM) lấy cảm hứng từ hành vi thị giác của con người với thuật toán dự kiến thực hiện như sau:

- **Bước 1 - Look-back:** Trích xuất đặc trưng toàn cục của ảnh gốc để nắm bắt ngữ cảnh đối tượng mà không cần bộ mã hóa văn bản (text encoder).
- **Bước 2 - Feature Matching:** So khớp đặc trưng của từng vùng ảnh với các vector nhúng “bất thường” và “bình thường” có khả năng học được. Kết quả đầu ra là một significance map chỉ ra xác suất lỗi tại từng vị trí pixel.

Tiếp theo, xây dựng bộ chọn lọc token (VT Selector) bằng cách xây dựng module sử dụng significance map từ LTFM để thực hiện phép nhân phần tử, giúp triệt tiêu các token nền và nhấn mạnh các token chứa thông tin bất thường. Các token này sau đó được tổng hợp lại bằng Q-Former để đưa vào LLM xử lý.

Cuối cùng, thực hiện huấn luyện với 2 giai đoạn:

- **Giai đoạn 1 - Professional Training:** Huấn luyện các module chuyên gia (Projector, Adaptor, LTFM parameters) với hàm mất mát cân bằng để tối ưu hóa khả năng phân biệt đặc trưng lỗi.
- **Giai đoạn 2 - Visual Instruction Tuning:** Đóng băng module chuyên gia và bộ mã hóa thị giác, chỉ tinh chỉnh LLM trên bộ dữ liệu Anomaly-Instruct-125k để mô hình học cách suy luận và diễn đạt ngôn ngữ tự nhiên theo phong cách chuyên gia.



3. Thiết lập chuẩn đánh giá VisA-D&R

Để định lượng hiệu quả của khả năng suy luận, chúng tôi sẽ xây dựng bộ benchmark VisA-D&R dựa trên tập dữ liệu VisA.

Phương pháp thực hiện:

- Đầu tiên, thực hiện gán nhãn và kiểm tra thủ công. Tuyển chọn 10 lớp đối tượng và thực hiện kiểm tra thủ công các cặp câu hỏi - đáp để đảm bảo độ chính xác tuyệt đối làm dữ liệu nền.
- Sau đó, tiến hành xây dựng kịch bản đánh giá, thiết kế các bộ metric đánh giá

riêng biệt cho hai tác vụ:

- Phát hiện - Detection: Sử dụng các metric đo lường như Accuracy, Precision, Recall, F1-score.
- Suy luận - Reasoning: Sử dụng GPT-Score với GPT-4 để chấm điểm sự tương đồng ngữ nghĩa.

KẾT QUẢ MONG ĐỢI

Việc triển khai thành công các nội dung trên dự kiến sẽ mang lại các sản phẩm khoa học và chỉ số hiệu năng cụ thể sau:

1. Tập dữ liệu huấn luyện chuyên biệt Anomaly-Instruct-125k

Xây dựng được bộ dữ liệu tinh chỉnh chỉ thị quy mô lớn nhất hiện nay Anomaly-Instruct-125k cho lĩnh vực AD với khoảng 125.000 mẫu, bao gồm cả dữ liệu công nghiệp, y tế và 3D.

2. Mô hình Anomaly-OneVision và mã nguồn huấn luyện

Đề xuất mô hình Anomaly-OneVision có khả năng phát hiện bất thường với độ chi tiết cao và khả năng suy luận giải thích lỗi. Thực nghiệm dự kiến có các chỉ số vượt trội so với các phương pháp hiện hành như WinCLIP, AnomalyCLIP và cơ chế reasoning như LLaVA hay Qwen-VL:

- Khả năng phát hiện (Detection):
 - Dự kiến đạt chỉ số AUROC tối thiểu 93% trên tập dữ liệu chuẩn MVTec AD, vượt qua các mô hình ZSAD hàng đầu như WinCLIP (91.8%) và AnomalyCLIP (91.5%).
 - Dự kiến đạt AUROC tối thiểu 90% trên tập VisA, cải thiện đáng kể so với các phương pháp trước đó.
- Khả năng suy luận (Reasoning):
 - Dự kiến đạt độ chính xác (Accuracy) trong việc trả lời câu hỏi phát hiện

lỗi không dưới 75%, vượt qua mô hình tổng quát GPT-4o (vốn thường gặp lỗi False Negative trên các chi tiết nhỏ).

- Điểm số suy luận (Reasoning Score) được đánh giá bởi GPT-4 dự kiến sẽ cao hơn các mô hình nguồn mở như LLaVA hay Qwen-VL.

3. Tính ứng dụng và mở rộng

Kết quả nghiên cứu sẽ chứng minh tính khả thi khi mở rộng sang các miền dữ liệu đặc thù:

- Y tế: Khả năng phát hiện và giải thích vùng tổn thương trên ảnh X-quang phổi hoặc MRI não.
- Hình ảnh 3D: Khả năng phát hiện lỗi hình học (lỗi, lõm) trên dữ liệu đám mây điểm được chuyển đổi sang dạng ảnh đa góc nhìn

TÀI LIỆU THAM KHẢO *(Định dạng DBLP)*

- [1]. Jiacong Xu, Shao-Yuan Lo, Bardia Safaei, Vishal M. Patel, Isht Dwivedi: Towards Zero-Shot Anomaly Detection and Reasoning with Multimodal Large Language Models. CVPR 2025: 20370-20382.
- [2]. Jongheon Jeong, Yang Zou, Taewan Kim, Dongqing Zhang, Avinash Ravichandran, Onkar Dabeer: WinCLIP: Zero-/Few-Shot Anomaly Classification and Segmentation. CVPR 2023: 19606-19616.
- [3]. Qihang Zhou, Guansong Pang, Yu Tian, Shibo He, Jiming Chen: AnomalyCLIP: Object-agnostic Prompt Learning for Zero-shot Anomaly Detection. ICLR 2024.
- [4]. Bo Li, Yuanhan Zhang, Dong Guo, Renrui Zhang, Feng Li, Hao Zhang, Kaichen Zhang, Peiyuan Zhang, Yanwei Li, Ziwei Liu, Chunyuan Li: LLaVA-OneVision: Easy Visual Task Transfer. Trans. Mach. Learn. Res. 2025 (TMLR).
- [5]. Paul Bergmann, Michael Fauser, David Sattlegger, Carsten Steger: MVTec AD - A Comprehensive Real-World Dataset for Unsupervised Anomaly Detection. CVPR 2019: 9592-9600.

[6]. Jinan Bao, Hanshi Sun, Hanqiu Deng, Yinsheng He, Zhaoxiang Zhang, Xingyu Li: BMAD: Benchmarks for Medical Anomaly Detection. CVPR 2024: 4042-4053.